

LeWorldModel 论文深度解析

让 AI 像人一样"想象未来"——从像素直接学习世界模型

论文原题: *LeWorldModel: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels*

发表时间: 2026 年 3 月 13 日 | 机构: Mila / 蒙特利尔大学、纽约大学 (含 Yann LeCun)、Brown 大学

论文链接: arxiv.org/abs/2603.19312

一、用一句话说清楚这篇论文在做什么

想象你要训练一个机器人, 让它学会"如果我做这个动作, 接下来会发生什么"。传统方法要么需要海量算力, 要么需要人工设计大量规则, 要么训练过程极不稳定。这篇论文提出了一个叫 **LeWorldModel (LeWM)** 的方法, 让 AI 只看视频画面 (像素) 就能自己学会"想象未来"——而且训练过程简单、稳定, 一块普通 GPU 几小时就能搞定。1

二、背景: 什么是"世界模型"?

在正式介绍论文之前, 我们先理解几个核心概念。

2.1 世界模型是什么

人类在做决策时, 脑子里会自动"模拟": 如果我推这个杯子, 它会掉下去; 如果我向左转, 我会看到走廊。这种在脑海中预测未来的能力, 就是"世界模型"。

AI 领域的**世界模型 (World Model)**, 就是让机器也拥有这种能力: 给定当前状态和一个动作, 预测下一个状态会是什么。有了世界模型, AI 就可以在"想象空间"里反复试验, 而不需要每次都真实执行动作, 大大提高学习效率。1

2.2 什么是"潜在空间" (Latent Space)

直接处理原始像素 (比如一张 224×224 的图片, 有 15 万个像素点) 计算量极大。研究人员的解决方案是: 先用一个**编码器 (Encoder)** 把图片压缩成一个小小的"摘要向量" (比如 192 维), 这个压缩后的空间就叫**潜在空间**。

打个比方: 你不需要记住一张脸的每一个毛孔, 你只需要记住"高鼻梁、大眼睛、圆脸"这几个关键特征, 就能认出这个人。潜在空间就是这些"关键特征"的集合。

世界模型在潜在空间里工作, 预测的是"关键特征的变化", 而不是"每个像素的变化", 效率大幅提升。1

2.3 什么是 JEPA（联合嵌入预测架构）

JEPA（Joint Embedding Predictive Architecture） 是 Yann LeCun（本文作者之一，深度学习三巨头之一）提出的一个框架。它的核心思想是：

- 把当前帧和未来帧都编码到潜在空间
- 在潜在空间里预测"未来的特征"，而不是直接预测"未来的像素"

这比直接预测像素要聪明得多——因为很多像素细节（比如背景的纹理）对于理解动作根本不重要，强迫模型预测这些细节是在浪费资源。 1

三、核心问题：训练 JEPA 为什么这么难？

JEPA 概念很美，但有一个致命的陷阱——**表示坍塌（Representation Collapse）**。

3.1 什么是表示坍塌

想象你让模型学习"预测未来的特征"。模型发现了一个作弊方法：**把所有输入都映射到同一个向量**（比如全零向量）。这样，"预测未来特征"的误差永远是零，损失函数完美满足——但这个模型完全没用，因为它把所有不同的场景都"看成一样的"。

这就是表示坍塌：模型学到了一个退化的、无意义的表示。 1

3.2 现有方法如何解决，以及它们的问题

方法	解决坍塌的手段	代价
DINO-WM	使用预训练的 DINOv2 编码器（冻结，不更新）	表示能力受限于预训练模型，无法端到端优化
PLDM	7 个损失项组合（VICReg 变体）	6 个超参数需要调，训练不稳定，调参复杂度 $O(n^6)$
Dreamer / TD-MPC	需要奖励信号或特权状态信息	只能用于特定任务，不通用
I-JEPA / V-JEPA	指数移动平均（EMA）+ 停止梯度（Stop-Gradient）	没有理论保证，是经验性技巧，可能引入新的不稳定

这些方法要么不能端到端训练，要么调参地狱，要么缺乏理论保证。 1

四、LeWM 的解决方案：优雅的两项损失

LeWorldModel 的核心创新是：用**两个损失项**解决上述所有问题，且有理论保证。 1

4.1 整体架构：编码器 + 预测器

LeWM 由两个模块组成：

Plain Text

原始图像帧 (224×224 像素)

↓ 编码器 (ViT-Tiny, ~5M 参数)

潜在向量 z_t (192 维)

↓ 预测器 (ViT-Small, ~10M 参数) + 动作 a_t

预测的下一帧潜在向量 $\hat{z}_{t+1}$

编码器使用 Vision Transformer (ViT) 的 Tiny 版本，将每帧图像压缩为 192 维向量。**预测器**使用 ViT-Small，接收当前潜在向量和动作，自回归地预测下一时刻的潜在向量。整个模型约 **1500 万参数 (15M)**，可在单块 GPU 上训练。¹

4.2 损失函数一：预测损失 (Prediction Loss)

这是最直观的部分：预测的未来特征，要和真实的未来特征尽量接近。

$$\mathcal{L}_{\text{pred}} = \|\hat{z}_{t+1} - z_{t+1}\|^2$$

用大白话说："你预测的下一帧特征，和真实的下一帧特征之间的距离越小越好。" 这是均方误差 (MSE)，最简单的损失形式。

但如前所述，单独使用这个损失会导致坍塌。

4.3 损失函数二：SIGReg (防坍塌正则化)

这是论文最核心的创新。**SIGReg (Sketched Isotropic Gaussian Regularizer, 草图各向同性高斯正则化器)** 的目标是：强制让所有潜在向量的分布，整体上服从标准正态分布 (高斯分布)。

为什么这能防止坍塌？

如果所有输入都被映射到同一个向量 (坍塌)，那这些向量的分布就是一个"点"，根本不像高斯分布。SIGReg 会惩罚这种情况，迫使模型让不同输入产生不同的、多样化的表示。

SIGReg 的具体做法 (通俗版)：

1. 随机选 1024 个方向 (单位向量)
2. 把所有潜在向量投影到每个方向上，得到 1024 组一维数据
3. 对每组一维数据，用统计检验 (Epps-Pulley 检验) 测量它"有多像正态分布"
4. 把 1024 组检验结果取平均，作为正则化损失

直觉理解：把一个高维球 (潜在空间) 从 1024 个不同角度"切片"，检查每个切片的形状是否像正态分布的钟形曲线。如果所有切片都像，那整体分布就接近高斯分布。这背后有严格的数学

定理（Cramér-Wold 定理）作为保证。 1

最终总损失：

$$\mathcal{L}_{\text{LeWM}} = \mathcal{L}_{\text{pred}} + \lambda \cdot \text{SIGReg}$$

只有一个超参数 λ （默认 0.1），且论文证明 λ 在 0.01 到 0.2 的宽泛范围内性能都很好，调参极其简单。相比之下，PLDM 有 6 个超参数，调参复杂度是 $O(n^6)$ ，而 LeWM 只需要二分搜索，复杂度仅 $O(\log n)$ 。 1

五、如何用世界模型做决策：潜在空间规划

训练好世界模型后，如何用它来控制机器人？LeWM 使用模型预测控制（MPC）在潜在空间中规划。 1

5.1 规划流程

Plain Text

给定：当前观测 o_1 （初始状态）和目标观测 o_g （目标状态）

↓

用编码器将两者压缩为潜在向量 z_1 和 z_g

↓

随机初始化一个动作序列 $[a_1, a_2, \dots, a_H]$

↓

用预测器在潜在空间中"想象"执行这些动作后的未来状态

↓

计算最终预测状态 $\hat{z}_H$ 与目标 z_g 的距离（代价函数）

↓

用交叉熵方法（CEM）优化动作序列，使代价最小

↓

执行前 K 步动作，重新观测，再规划（滚动规划）

打个比方：就像你在脑海中预演"怎么把桌上的杯子推到指定位置"——先想象推一下，再想象再推一下，反复调整，直到想象中的结果和目标一致，然后才真正动手。

5.2 规划速度优势

LeWM 将每帧图像压缩为 192 维向量，而 DINO-WM 使用的 DINOv2 编码器会产生约 200 倍更多的 token（patch embeddings）。这使得 LeWM 的规划速度比 DINO-WM 快 48 倍，整个规划过程在 1 秒内完成，接近实时控制。 1

六、实验结果：LeWM 表现如何？

6.1 测试环境

论文在 4 个不同的控制任务上进行了测试，覆盖 2D 和 3D 场景：

环境	类型	任务描述
Push-T	2D 操控	用蓝点推动 T 形方块到目标位置
Reacher	2D 运动控制	控制二关节机械臂到达目标位置
Two-Room	2D 导航	穿过门洞从一个房间导航到另一个房间
OGBench-Cube	3D 操控	机械臂抓取并放置方块到目标位置

6.2 规划性能对比

方法	Push-T 成功率	规划速度	训练方式
LeWM (本文)	96%	~1 秒/次	端到端，单 GPU
DINO-WM	92%	~48 秒/次	需预训练编码器
PLDM	78% (±5%，不稳定)	~1 秒/次	端到端，但 7 项损失
GCBC (行为克隆)	较低	—	需要奖励信号

LeWM 在 Push-T 上以 **96% 的成功率**超越所有对比方法，训练方差也最小 (±2.83%)，说明训练极其稳定。值得注意的是，在最简单的 Two-Room 环境中，LeWM 表现略逊——这是因为该环境的数据多样性太低，SIGReg 强制高斯分布的效果反而不理想，这也是论文诚实指出的局限性。

1

6.3 训练稳定性对比

论文对比了 LeWM 和 PLDM 的训练曲线：

- **LeWM**：两条损失曲线（预测损失 + SIGReg）都平滑单调下降，训练过程清晰可控。
- **PLDM**：7 条损失曲线相互竞争，多条出现震荡和非单调行为，训练过程混乱。

这直观地说明了"少即是多"的设计哲学——越少的损失项，越容易训练稳定。 1

七、模型真的"理解物理"了吗？

这是论文最有趣的部分。研究者不满足于"模型能完成任务"，还想知道：**模型的潜在空间里到底编码了什么物理信息？**

7.1 物理量探针实验（Probing）

研究者训练了一个简单的线性分类器，尝试从 LeWM 的潜在向量中"读出"各种物理量（位置、角度等）。

打个比方：就像给一个人蒙上眼睛，只让他摸一个物体，然后问他"这个物体在哪里？"——如果他答对，说明他的触觉信息里确实编码了位置信息。

Push-T 环境探针结果（Pearson 相关系数，越接近 1 越好）：

物理量	LeWM（线性）	PLDM（线性）	DINO-WM（线性）
智能体位置	0.974	0.955	0.977
方块位置	0.986	0.938	0.997
方块角度	0.902	0.745	0.979

LeWM 在位置信息上接近甚至超越 PLDM，但在角度信息上略逊于 DINO-WM。这是合理的：DINO-WM 使用了在 1.24 亿张图片上预训练的 DINOv2，天然具备丰富的视觉先验；而 LeWM 只用了几万条轨迹，却达到了相近的效果，性价比极高。 ¹

7.2 违反预期实验（Violation of Expectation）

这个实验来自发展心理学：给婴儿看"不可能发生的事情"（比如物体凭空消失），婴儿会盯着看更久，说明他们"感到惊讶"——这证明婴儿已经有了基本的物理直觉。

研究者对 LeWM 做了类似测试：

- **正常轨迹：**物体按物理规律运动
- **视觉扰动：**物体颜色突然变化（外观变了，但物理没变）
- **物理扰动：**物体突然瞬移到随机位置（违反物理连续性）

LeWM 的"惊讶度"（预测误差）：



结论：LeWM 对物理违规（瞬移）的惊讶度显著高于颜色变化 ($p < 0.01$)，说明它更关注物理连续性而非表面视觉特征。这表明模型确实学到了某种程度的"物理直觉"，而不仅仅是在做像素级的模式匹配。 1

八、一个意外发现：潜在轨迹自发变"直"

论文还记录了一个有趣的涌现现象，灵感来自神经科学。

时间直线化假说：神经科学家发现，人类视觉皮层会把复杂的视频序列表示为潜在空间中近似直线的轨迹，这有助于外推和预测。

研究者发现：**LeWM 在训练过程中，潜在轨迹自发地变得越来越"直"**——即使训练目标里完全没有鼓励这一点的项！而 PLDM 虽然有专门的"时间平滑损失"来鼓励直线化，最终的直线度反而不如 LeWM。

这说明 SIGReg 的高斯约束在时间维度上留下了"自由度"，让模型自然地发展出了直线化的时间表示——这是一个优雅的涌现行为。 1

九、消融实验：每个设计选择都重要吗？

论文系统测试了各个设计选择的影响：

设计选择	关键发现
SIGReg 投影数量 (M)	从 256 到 2048 变化，性能几乎不变 → 不需要调
嵌入维度	低于 ~184 维性能下降，高于此值饱和 → 192 是好选择
预测器大小	ViT-S 最佳 (96%)，ViT-T 下降 (80.67%)，ViT-B 略降 (86.7%)
加入重建损失	性能反而下降 (96% → 86%) → 重建损失有害无益
编码器架构	ViT 和 ResNet-18 都能用 (96% vs 94%) → 架构无关
预测器 Dropout	$p=0.1$ 最佳 (96%)， $p=0$ 下降 (78%) → 适度 Dropout 很重要
λ (正则化权重)	$\lambda \in [0.01, 0.2]$ 内性能稳定在 80% 以上 → 鲁棒

这些消融实验证明了 LeWM 的设计是**鲁棒的**——大多数超参数不需要精细调整，模型对各种变化都不敏感。 1

十、局限性与未来方向


论文诚实地指出了三个主要局限性：

规划视野短：当前方法只能规划短期动作序列，长期规划（比如"完成一个需要 100 步的任务"）仍然困难。未来可以探索分层世界模型。

依赖离线数据集：模型需要预先收集的轨迹数据，且数据需要有足够的多样性。在数据极度单一的简单环境中（如 Two-Room），SIGReg 的效果会打折扣。

需要动作标签：预测器需要知道每一步执行了什么动作，这在某些场景下难以获取。未来可以通过逆动力学建模来减少对动作标签的依赖。 1

十一、总结：这篇论文的贡献与意义



这篇论文的核心贡献可以用三个词概括：**简单、稳定、高效。**

它证明了一个重要原则：**好的归纳偏置（SIGReg 的高斯约束）比复杂的工程技巧（7 项损失、EMA、Stop-Gradient）更有效。**通过将问题简化到本质，LeWM 不仅在性能上超越了更复杂的方法，还获得了理论上的训练稳定性保证，并意外地涌现出物理理解能力和时间直线化等有趣特性。

对于 AI 研究者而言，这是一个很好的提醒：在追求复杂性之前，先问问"最简单的方案是什么"。 1

参考文献

[1] LeWorldModel: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels | arXiv 2603.19312